

spoiler: no funcionó



La saga épica de:

¿Sirve meterle **Random Forest** a un **LightGBM**?

Impacto de variables derivadas de RF sobre las ganancias de un modelo predictivo LightGBM.

LOS RESPONSABLES

Ricardo Aníbal Cheluja ← esta gente
Santino Cantisano

EL CRIMEN

Maestría en Ciencia de Datos

Hipótesis Experimental

OBJETIVO GENERAL

Determinar si la incorporación de variables derivadas de Random Forest mejora las ganancias de un modelo LightGBM.

H_0 • HIPÓTESIS NULA

Agregar variables derivadas de RF **no produce una mejora significativa** en la ganancia del LightGBM respecto del base.

la aburrida

H_1 • HIPÓTESIS ALTERNATIVA

Agregar variables derivadas de RF **produce una mejora significativa** en la ganancia del LightGBM.

la esperanzada

Bibliografía

 EL BOOSTING

LightGBM

Ke et al., 2017

 EL BOSQUE

Random Forest

Breiman, 2001 · un clásico atemporal

 EN CASTELLANO

Amat Rodrigo, J. (2017). Árboles de decisión, RF, gradient boosting y C5.0.

cienciadedatos.net/documentos/33

 EL BLOG DE MEDIUM

Adele, G. (2021). Using Random Forests to generate partially synthetic categorical data.

medium.com/@gideonadele

"Cita o estarás cometiendo el peor crimen posible para un ser humano: el plagio" —Yo

Sesgos Cognitivos (los villanos)



Sesgo de Confirmación

confirmation bias

"lo veo porque lo quería ver"



Overfitting a Validación

val-set worship

el modelo memoriza, no aprende



Múltiples Comparaciones

tirá el dado 100 veces

algo va a dar significativo, dale



Cherry Picking

cherry picking

"mostramos SOLO la corrida buena"

Diseño Experimental

MODELO A • CONTROL

LightGBM base 🍞

solo variables originales, el pan de cada día

MODELO B • TRATAMIENTO

LightGBM + RF 🥪

le agregamos las variables derivadas de RF



Optimización

Bayesiana. Rangos de búsqueda, iteraciones y función objetivo.



Validación

Elegimos el mejor modelo por **ganancia** . Sí, la métrica del negocio.



Evaluación final

Testing con mismas semillas + Wilcoxon apareado.

Experimentos · Grilla de hiperparámetros

num_iterations

20 · 40 · 60 · 100

num_leaves

8 · 16 · 24 · 32

min_data_in_leaf

50 · 100 · 150 · 200

feature_fraction_bynode

0,1 · 0,2 · 0,3 · 0,4

y las recomendaciones dicen...

HIPERPARÁMETRO	Nuestro modelo	Recomendación 1	Recomendación 2
num_iterations	20	10-30	30-50
num_leaves	32	40-50	40-50
min_data_in_leaf	150	50-100	100-200
feature_fraction	0.1	0.1	0.1

Limitaciones



Dataset gigante

y tiempos de procesado más gigantes



Un solo problema de negocio

solo miramos ganancias



Cantidad limitada de semillas

cinco, para ser honestos



Una sola implementación de RF

el ranger, y no lo de las películas



Solo un algoritmo de boosting

LightGBM y punto



Sensibilidad a hiperparámetros

quién sabe qué pasa con otra grilla

Resultados · Ganancias por semilla

SEMILLA	CON RF	SIN RF	Δ (SIN - CON)
157627	595	598	+3
386003	581	579	-2
548177	586	612	+26
874127	585	589	+4
936931	571	598	+27

PROMEDIO

CON RF ·
583.6

SIN RF ·
595,2

MEDIANA

585

598

VECES QUE GANÓ

1 de 5


4 de 5 

WILCOXON

p = 0.0625




tan cerca... y sin embargo tan lejos

Importancia de variables · Modelo base vs. Modelo con RF

SIN variables RF Modelo Base			CON variables RF Modelo con RF		
POS	VARIABLE	GAIN	POS	VARIABLE	GAIN
1	ctrx_quarter_normalizado	0.050	1	rf_005_003	0.067
2	ctrx_quarter	0.041	2	rf_020_010	0.037
3	vm_status 01	0.027	3	ctrx_quarter	0.029
4	mcaja_ahorro	0.027	4	foto_mes	0.019
5	ctrx_quarter_normalizado_lag1	0.022	5	numero_de_cliente	0.018
6	mtarjeta_visa_consumo	0.022	6	mcuentas_saldo	0.016
7	mcuentas_saldo_lag1	0.015	7	mcaja_ahorro	0.014
8	mcuentas_saldo	0.013	8	rf_002_007	0.014
9	mcaja_ahorro_lag1	0.012	9	mtarjeta_visa_consumo	0.012
10	foto_mes	0.011	10	cliente_edad	0.010
11	mpayroll_sobre_edad	0.011	11	vm_status02	0.010
12	mpayroll	0.010	12	cpayroll_trx	0.008
13	ctrx_quarter_lag1	0.010	13	cliente_antiguedad	0.008
14	mprestamos_personales	0.010	14	mactivos_margen	0.007
15	ctarjeta_visa_transacciones	0.009	15	rf_019_005	0.007
16	cdescubierto_preacordado_tend6	0.009	16	mrentabilidad	0.007
17	cpayroll_trx	0.009	17	mpayroll_sobre_edad	0.007
18	mcuenta_corriente	0.008	18	mpasivos_margen	0.007
19	mpasivos_margen_lag1	0.008	19	mrentabilidad_anual	0.007
20	mrentabilidad_anual_lag2	0.007	20	cdescubierto_preacordado_tend6	0.006

las rf_XXX son las derivadas de RF · aparecen 5 en el top 20

Resultados · Semilla primigenia 157627



qué muestran las curvas

Ganancia acumulada vs. cantidad de envíos. El pico marca el corte óptimo para maximizar ganancia.

y el ganador es...

Sin RF llega a **598** con más envíos. Con RF pico más ajustado (10.764) pero **ganancia menor**.

Discusión

Las variables derivadas de RF no aportaron información predictiva adicional al modelo.

Aun así, **5 de esas variables** aparecieron en el **top 20** de importancia. → ruidosas pero populares

Las variables originales de **actividad transaccional y saldos** siguen mandando en el ranking.

La mejora debe evaluarse considerando tanto la **magnitud del efecto** como su **significación estadística**.

moraleja de la fábula

No justifica usar variables derivadas de RF en este dataset.

Tampoco lo comparamos con otros métodos de ingeniería de variables — otra pelea, otro día.

Conclusiones



Comparamos LightGBM base vs. LightGBM enriquecido con variables de RF.



Evaluamos con ganancias, AUC y prueba de Wilcoxon.



Identificamos las variables de mayor importancia en ambos modelos.

titular del día ↓

La incorporación de variables derivadas de Random Forest **NO** produjo una mejora estadísticamente significativa en las ganancias respecto del LightGBM base en nuestro dataset.

Recomendaciones

TIP #01

Validar el método en otros datasets.
quizás en el tuyo sí

TIP #02

Explorar otros algoritmos de feature engineering automático.

TIP #03

Mantener múltiples semillas + pruebas estadísticas serias.



la de oro:

Incorporar variables derivadas de RF **solo** cuando la mejora sea estadísticamente significativa — *porque el costo computacional se paga siempre* .

Futuros problemas y experimentos

☐ Aumentar la cantidad de semillas.☐ Comparar configuraciones del Random Forest.☐ Experimento de ablación.☐ Otros métodos de ingeniería de variables.☐ Costo computacional medido.☐ Validación temporal en múltiples meses.☐ Evaluar distintas cantidades de variables RF.☐ Optimización independiente vs. compartida.☐ Estabilidad de la importancia de variables.☐ Generalización fuera del período estudiado.

— la próxima generación de tesisas, ustedes saben qué hacer 🤔

la letra chica
↓

Anexo — o "los backups"



**Código
s**



**Parámetro
s**



Semillas



Versiones de software



**Config. optimización
bayesiana**



Tablas completas



Resultados de todas las corridas



Gráficos adicionales



**Script
s**

todo lo que no cabía en 14 diapositivas ✂

sí, ya terminamos



¡Muchas gracias!